1. INTRODUÇÃO

Desde seu reaparecimento em 1981, após ser considerada erradicada, a dengue é agora um mal endêmico no Brasil (Câmara et al., 2007). Entre os sintomas típicos estão febre elevada, dor muscular, mal-estar geral, inapetência e cefaleia. Em situações mais severas, a doença pode provocar hemorragias e até a morte do indivíduo (Graciano et al., 2017). Esses sintomas são causados por uma de cinco variantes do vírus DENV (Mustafa et al., 2015), e atualmente os sorotipos DENV-1 a DENV-4 circulam pelo território brasileiro. A infecção por um tipo do vírus não oferece imunidade contra os outros, mantendo o paciente suscetível a novas infecções (Neto, Nascimento, Sousa, 2016). Além disso, o vetor da dengue, o mosquito Aedes aegypti, encontra nos climas tropicais como o do Brasil, condições ideais para reprodução. Problemas como o descarte inadequado de resíduos sólidos e esgotos contribuem para a proliferação dos locais de deposição de ovos do mosquito (de Souza & Albuquerque, 2018).

Para combater essa ameaça constante, o Brasil utiliza a vacina Dengvaxia, que é regulamentada e disponível apenas no setor privado, recomendada exclusivamente para quem já foi infectado pela doença (da Silveira, 2019). Ações governamentais incluem campanhas de conscientização e medidas para controlar a proliferação do mosquito (Ferreira et al., 2019). Notavelmente, em 2019, a Organização Mundial da Saúde (OMS) contabilizou cerca de 4.2 milhões de casos de dengue em todo o mundo e destacou a doença como uma grave ameaça à saúde global. No mesmo ano, o Brasil enfrentou um aumento significativo de casos devido à emergência de uma nova variante do DENV-2, o que resultou em um crescimento de até 149% nos casos em alguns estados (Brasil, 2019; De Jesus et al., 2020).

A complexidade dos fatores que influenciam a proliferação da dengue torna seu controle e previsão desafiadores. No

entanto, avanços em Machine Learning e Deep Learning têm mostrado grande promessa para melhorar as pesquisas na área. Um exemplo notável foi um estudo realizado na Índia, onde técnicas de Deep Learning foram utilizadas para analisar variáveis climáticas, conseguindo prever surtos de dengue com 89% de precisão (Doni e Sasipraba, 2020). Em um esforço similar na Tailândia, pesquisadores utilizaram essas tecnologias para integrar dados ambientais e buscas no Google em suas análises, visando a previsão de incidências da doença (Puengpreeda et al., 2020).

Dada a vasta quantidade de pesquisa com artigos identificados em uma revisão sistemática, esta pesquisa procura aprofundar o entendimento sobre as estratégias utilizadas para combater a dengue utilizando Machine Learning e Deep Learning. Inovadoramente, incorporaremos ferramentas como TPOT e AutoML nesta análise. TPOT ajudará a automatizar a seleção e configuração de pipelines de Machine Learning usando programação genética para explorar milhares de possibilidades e identificar a configuração ideal sem intervenção manual intensiva.

Adicionalmente, o uso do AutoML, que abrange desde a seleção e pré-processamento de dados até a finalização de modelos, promete otimizar o processo de desenvolvimento dos modelos. Este projeto não só visa acelerar a produção de modelos preditivos, mas também tornar o Machine Learning acessível a um público mais amplo, democratizando a tecnologia de inteligência artificial. A integração de TPOT e AutoML é um passo estratégico para aumentar a produtividade, otimizar resultados e oferecer um método mais eficiente e acessível para prever surtos de dengue, maximizando o uso destas tecnologias avançadas.

2. MATERIAL E MÉTODOS

2.1 Base de Dados

Os dados utilizados neste estudo provêm de duas fontes principais:

DATASUS: Foram coletados registros de todos os casos de dengue no município de Presidente Prudente de 2014 a 2024, focando nas semanas epidemiológicas de cada ano.

INMET (Instituto Nacional de Meteorologia): Dados climáticos horários de 2014 a 2024 foram obtidos, incluindo variáveis como temperatura, umidade, pressão atmosférica, entre outros. Esses dados foram processados para calcular médias diárias e semanais que correspondem às semanas epidemiológicas dos dados de dengue.

2.2 Preparação dos Dados

Os dados horários do INMET tiveram lacunas preenchidas usando as médias das duas horas anteriores, cobrindo 22 lacunas existentes. A integração dos dados climáticos e epidemiológicos foi realizada em uma única planilha, consolidando variáveis climáticas e epidemiológicas para análise correlativa. Esta planilha incluiu a precipitação total acumulada de cada semana, desde a segunda até a 16ª semana, junto com outras variáveis climáticas ajustadas para períodos semanais.

2.2 Ferramentas Utilizadas

Python e Bibliotecas

A análise foi realizada utilizando Python, especificamente dentro do Jupyter Notebook. As principais bibliotecas utilizadas incluíam:

- Pandas: Essencial para a manipulação e preparação dos dados, como a remoção de duplicatas, tratamento de valores ausentes e exclusão de colunas potencialmente enviesadas.
- Seaborn: Usada para a visualização de dados, incluindo a produção de matrizes de correlação.
- Sklearn (Scikit-learn): Aplicada na normalização dos dados e na implementação do modelo SVM para previsões.
- TPOT: O processo de Análise Exploratória de Dados (AED) ajudou a identificar as principais variáveis e a preparar o dataset para a modelagem preditiva. Para a otimização do modelo de máquina de aprendizado, foi utilizado o TPOT (Tree-based Pipeline Optimization Tool), uma biblioteca que automatiza a seleção e configuração dos modelos preditivos baseados em algoritmos genéticos.

2.3 Modelagem e Avaliação

Iniciamos nossa análise de dados com a aplicação da Análise de Componentes Principais (PCA), uma técnica estatística projetada para reduzir a dimensionalidade dos conjuntos de dados enquanto preserva o máximo de informação possível. Essa técnica

identifica as direções, denominadas componentes principais, nas quais a variação dos dados é maximizada.

Fundamentos dos Diferentes Componentes Principais

O PCA busca essas direções de maior variação em um espaço de dados multidimensional. Cada componente principal (PC) captura uma proporção significativa da variação total, com cada componente subsequente capturando progressivamente menos variação sob a condição de ser ortogonal aos anteriores. Isso assegura que cada novo componente principal oferece insights independentes dos já considerados.

Detalhamento das Cargas do PCA

1. **PC1 (Primeiro Componente Principal):** Predominantemente captura variações relacionadas à temperatura do ponto de orvalho e acumulados de precipitação por várias semanas. Essa configuração sugere que o PC1 está associado a tendências climáticas de longo prazo, particularmente aquelas relacionadas à umidade e à precipitação acumulada.

2. **PC2 (Segundo Componente Principal):** Caracteriza-se por cargas negativas significativas nas temperaturas máxima, média e mínima, além de uma forte influência negativa da pressão atmosférica e uma carga moderadamente negativa para a velocidade máxima da rajada de vento. Isso indica que o PC2 captura flutuações diárias ou sazonais pronunciadas na temperatura e pressão atmosférica.

3. **PC3 (Terceiro Componente Principal):** Apresenta fortes cargas negativas para precipitação total e umidade relativa mínima, com uma influência moderada do acumulado de 2 semanas. Esse

componente parece estar relacionado a variações abruptas ou eventos específicos, como períodos de seca ou chuvas intensas.

4. **PC4 (Quarto Componente Principal):** Exibe cargas negativas moderadas associadas à umidade relativa média e mínima, indicando que este componente pode estar capturando variações de umidade não explicadas por outros componentes.

5. **PC5 (Quinto Componente Principal):** Concentra-se mais nas características do vento, particularmente na velocidade média do vento e na rajada máxima, sugerindo que esta componente captura aspectos específicos do comportamento do vento distintos de outras variáveis climáticas.

VARIÁVEL	PC1	PC2	PC3	PC4	PC5
Precipitacão Total (mm)	0.537135	-	-0.609034	-	-
Pressão Atmosférica (mB)	-	0.743673	-	-	-
Temperatura Ponto Orvalho (°C)	0.705313	-	-	-	-
Temperatura Máxima (°C)	-	-0.926880	-	-	-
Temperatura Média (°C)	-	-0.925275	-	-	-
Temperatura Mínima (°C)	-	-0.826513	-	-	-
Umidade Relativa Media	0.628048	-	-	-0.511273	-
Umidade Relativa Mínima	0.572170	-	-0.508900	-0.510786	-
Vento Rajada Máxima (m/s)	-	-0.530554	-	-	-0.617125
Vento Velocidade Média (m/s)	-	-	-	-	-0.823443
Acumulado 2 Semanas (mm)	0.686189	-	-0.520941	-	
Acumulado 3 Semanas (mm)	0.781539	-	-	-	-
Acumulado 4 Semanas (mm)	0.844924	-	-	-	-
Acumulado 5 Semanas (mm)	0.889220	-	-	-	-
Acumulado 6 Semanas (mm)	0.917733	-	-	-	-
Acumulado 7 Semanas (mm)	0.936619	-	-	-	-
Acumulado 8 Semanas (mm)	0.947250	-	-	-	-

Após a identificação das variáveis que mostraram a maior correlação com a incidência de casos de dengue, empregamos o TPOT, uma ferramenta de otimização automática de pipeline de aprendizado de máquina, para determinar o modelo mais eficaz para explicar os dados. Após uma extensa série de 100 gerações de ajustes e otimizações,

o melhor desempenho interno, medido pelo score de validação cruzada (CV score), alcançado foi de 0.7524. O modelo mais eficaz, identificado por este processo, foi o classificador XGBClassifier, configurado com parâmetros meticulosamente ajustados para maximizar a precisão:

- Taxa de aprendizado (learning rate): 0.01
- Profundidade máxima (max depth): 10
- Peso mínimo por filho (min child weight): 9
- Número de estimadores (n_estimators): 100
- Número de jobs simultâneos (n_jobs): 1
- Subamostra (subsample): 1.0
- Verbosidade (verbosity): 0

Esta configuração resultou em uma acurácia do modelo de 73.53%, destacando a eficácia do XGBClassifier quando ajustado apropriadamente. A especificação detalhada do pipeline utilizado é apresentada a seguir, fornecendo uma visão clara da estrutura e dos parâmetros que contribuíram para o desempenho superior do modelo.

python Copy code

```python
Pipeline(steps=[
    ('xgbclassifier', XGBClassifier(
        base_score=None, booster=None, callbacks=None,
        colsample_bylevel=None, colsample_bynode=None,
        colsample_bytree=None, device=None, early_stopping_rounds=None,
        enable_categorical=False, eval_metric=None, feature_types=None,
        gamma=None, grow_policy=None, importance_type=None,
        interaction_constraints=None, learning_rate=0.01, max_bin=None,
        max_cat_threshold=None, max_cat_to_onehot=None, max_delta_step=None,
        max_depth=10, max_leaves=None, min_child_weight=9, missing=np.nan,
        monotone_constraints=None, multi_strategy=None, n_estimators=100,
        n_jobs=1, num_parallel_tree=None, objective='multi:softprob', ...)
    )
])
```

FIGURA 1 - Melhor modelo e sua respectiva configuração.

2. CONCLUSÃO

Através da aplicação de técnicas avançadas de machine learning, incluindo TPOT e AutoML, este estudo demonstrou a capacidade de modelos de previsão para identificar e responder eficazmente à dinâmica de transmissão da dengue. A modelagem resultou em um score de validação cruzada de 0.7524, refletindo uma acurácia substancial, mas com espaço para aprimoramentos futuros através da inclusão de mais dados e refinamento do modelo.

A análise de componentes principais (PCA) foi uma etapa fundamental, revelando as principais direções de variância nos dados climáticos e epidemiológicos. Os resultados mostraram que o primeiro componente principal (PC1) capturou variações significativas associadas principalmente à temperatura do ponto de orvalho e à precipitação acumulada ao longo de várias semanas, sugerindo uma forte ligação com tendências climáticas de longo prazo. PC2 revelou sensibilidade às flutuações nas temperaturas máxima, média e mínima, além de mudanças na pressão atmosférica, capturando as variações mais pronunciadas associadas a padrões climáticos sazonais ou diários.

O terceiro componente principal (PC3) destacou-se pela detecção de variações abruptas, como períodos de seca ou chuvas intensas, através de cargas negativas para precipitação total e umidade relativa mínima. Os componentes PC4 e PC5 identificaram nuances mais sutis nas variações de umidade e no comportamento do vento, respectivamente, indicando a capacidade do PCA de distinguir complexidades multidimensionais nos dados climáticos que podem influenciar diretamente a proliferação do vetor da dengue.

Essas descobertas sublinham a importância de integrar análises climáticas detalhadas com estratégias de machine learning para criar ferramentas preditivas mais eficazes. Estas, por sua vez, podem

oferecer às autoridades de saúde pública insights mais precisos e tempestivos, permitindo intervenções mais direcionadas e eficientes na luta contra a dengue. A colaboração contínua entre as áreas de epidemiologia, climatologia e ciência de dados é essencial para o desenvolvimento de soluções que possam mitigar o impacto da dengue e outras doenças transmitidas por vetores, contribuindo para a saúde pública global.